Assignment #1

2023480023 정태양

Table 1: MNIST Results (PGD: k=40, eps_step=0.01)

Attack	0.01	0.05	0.1	0.2	0.3	0.5
Targeted FGSM	0.20	0.49	1.56	12.89	39.26	41.41
Untargeted FGSM	1.37	4.88	15.43	55.37	84.57	93.16
Targeted PGD	0.20	0.59	3.81	69.34	99.90	100.00
Untargeted PGD	1.37	6.25	26.56	98.44	100.00	100.00

Table 2: CIFAR-10 Results (PGD: k=10, eps_step=0.01)

Attack	0.01	0.05	0.1	0.2	0.3	0.5
Targeted FGSM	23.73	12.70	8.59	8.20	8.79	8.20
Untargeted FGSM	78.32	87.40	89.65	90.53	89.65	90.23
Targeted PGD	75.29	100.00	100.00	100.00	100.00	100.00
Untargeted PGD	99.12	100.00	100.00	100.00	100.00	100.00

Discussion

실험 결과 모든 조건에서 PGD가 FGSM보다 압도적으로 높은 성공률을 보였다.
이는 한 번의 스텝으로 Loss를 근사하는 FGSM에 비해, PGD는 k번의 반복을 통해 Loss 업데이트 방향을 재계산하기 때문에 보다 유의미한 결과를 도출 할 수 있는것으로 보인다.

시각화 이미지를 통해 Epsilon값이 커질수록 SR은 높아지지만 원본 이미지에 큰 perturbation이 더해져 눈에 띈다는 trade off를 확인할 수 있었다.

또, Dataset간의 최적의 epsilon값이 달랐는데 이는 각 Dataset의 특징의 차이로, Table에서 확인되는 것과 같이
MNIST는 흑백이고 단순한 형태이기 때문에 모델이 맞추기 쉬워 높은 SR을 위해서 큰 epsilon이 필요하고
CIFAR-10은 작은 epsilon에서도 모델의 추론 능력이 떨어진다는 점을 알 수 있었다.

가장 흥미로운 점은 CIFAR-10의 Targeted FGSM이 높은 epsilon에서 비교적 낮은, 심지어 MNIST보다 낮은 SR 보인 부분이다. 이는 단일 스텝 방식인 FGSM에서 epsilon 값이 높아지면 한 스텝에서 과도하게 큰 업데이트로 인해 타겟클래스의 영역을 완전히 벗어나는것으로 풀이된다.
Untargeted 에서는 약 90%의 SR을 보이는 것으로 보아 에러율은 그대로 높지만 '목표로 한 타겟'은 빗나가는 것으로 분석할 수 있었다.