Assignment #2

2023480023 정태양

Problem 1: DeepXplore

jialicheng/cifar10_resnet-50, jialicheng/unlearn-so_cifar10_resnet-50_salun_10_100에서 불러온 두 사전학습 모델을 사용했으며 출처 및 초기화,하이퍼파라미터정보는 README에 기록해두었다.

위의 두 모델로 DeepXplore를 실행하였다. 이때 모델과 CIFAR-10에 맞는 패키지와 버전을 위해 기존 파일을 수정한 CIFAR10_torch 폴더를 생성하여 해당 폴더 내에서 DeepXplore가 작동하도록 구현하였다.

DeepXplore 실행 결과, 총 11개의 불일치 사례를 확보했다. 이 중 4개는 원본 입력 자체에서 이미 불일치한 경우였다.
average neuron coverage는 약 0.00132이고 0.00077~0.00166의 범위를 가진다.
불일치 발생 경우에 대해서는 동물클래스에서 전체 중 8건으로 많은 비율을 차지했다. 이는 실험에서 사용한 occlusion 기반의 perturbation이 국소 영역만을 대상으로 gradient를 더해주는 방식으로 얼굴, 꼬리, 다리 등의 국소적 특징에 의존하는 동물 클래스의 특성 상 모델의 판단이 달라졌을 것으로 판단된다.

Problem 2 : Connecting Attacks and Testing

FGSM의 적대적 공격과 DeepXplore의 테스트를 결합하면 신경망 테스트를 더욱 가속할 수 있다.

기존 DeepXplore에서는 모델에 light, occl, blackout과 같은 무작위 노이즈를 통해 불일치를 만들어낸다. 이때 FGSM으로 생성한 미세한 적대적 이미지를 초기 입력(Seed)로 사용하면 기존의 입력보다 모델의 결정 경계에 인접해 있으므로 효율적으로 버그를 찾고 뉴런 커버리지를 극대화 할 수 있다. 더 나아가 FGSM의 목적 함수를 단순 오분류가 아닌 뉴런 커버리지 최대화로 변경하면 모델의 심층적인 결함 파악이 가능할 것이다.

다만 적대적 공격 시 perturbation이 과하게 클 경우, 이미지가 크게 변화하여 원본 의미가 훼손되어 DeepXplore가 의미없는 불일치만 식별하게 되는 한계점도 존재한다. 따라서 perturbation을 미세하게 제한하여 테스트의 현실성을 유지하는 것이 중요할 것이다.