

Assignment #3

2023480023 정태양

Problem 1: Explore the Marabou Resources Directory

Models:

nnet/ 하위에는 Forward Neural Network 기반의 모델들이 .nnet 포맷으로 제공됨. 항공기충돌 회피 모델 ACASXU와 MNIST 이미지 분류 모델도 포함되어있음. 이외에도 외부 모델 검증 시, .nnet 외에 .onnx, .mps, .h5와 같은 모델도 활용할 수 있음.

Datasets or Input specifications:

resources 폴더에는 원본 데이터셋 대신 검증을 위한 모델과 입력 제약 정보가 포함되어있음. ACASXU, MNIST 위주로 구성되어있음.

Verification query examples:

properties/ 하위에 제약 조건을 담은 .txt 파일들이 있음. 이는 이미지에 대해 여러 범위의 노이즈 강건성을 검증하는 부등식들로 구성되어있으며 ACASXU, MNIST 이미지를 대상으로 함.

bnn_queries/ 에는 검증을 위한 쿼리가 포함되어있음.

Problem 2: Run Marabou with an External Model and Dataset

Marabou 설치 및 예제 실행과정에서 최신 버전의 CMake와 pybind11(c++코드를 python에서 쓸 수 있게 해주는 도구)간 호환 문제가 발생하여 cmake 버전을 3.x 계열로 맞추어 해결하였다.

이후 Marabou에서 제공하는 1_ONNXExample.py를 실행하여 정상 설치를 확인하였다.

외부 모델로 sklearn digits 데이터셋으로 직접 학습한 2 layer CNN을 사용했으며, 입력 크기가 8*8으로 모델이 작아 Marabou가 처리하기에 적합하다고 판단하였다. 입력은 [0,1]으로 정규화 하였고, 학습 이후 ONNX로 변환했다.

검증은 Marabou의 Python API인 maraboupy로 수행했다.

모델은 테스트셋에서 약 95.83%의 정확도를 보였으며, 테스트셋에서 올바르게 분류된 샘플에 대해 L_∞ 거리가 0.01 범위 안에 있는 샘플도 원래 클래스를 유지하는지 확인하기 위해 다른 클래스에서 잘못 예측하는지 확인하였다.

이때 선택된 샘플은 index= 348, label= 6이었으며, 모든 target 클래스에 대한 결과는 UNSAT이었다. 각 검증 시간은 0.01~0.02초로 확인하였다. 따라서 이 샘플은 epsilon=0.01 범위에서 locally robust 하다고 해석할 수 있다.

추가로 adversarial input을 확인하기 위해 epsilon=0.2 범위에서 실험하였을때 원본 샘플의 class 6에서 0으로 오분류되는 결과를 확인할 수 있었다.

Report

```
(rai) ➔ hw3 git:(main) ✕ python test.py --epsilon 0.01


[setup] loading sklearn digits dataset
[setup] training small 2-layer CNN
[train] epoch=01 loss=2.3061
[train] epoch=05 loss=1.9715
[train] epoch=10 loss=0.4420
[train] epoch=15 loss=0.7389
[train] epoch=20 loss=0.1630
[eval] test_accuracy=0.9583
[sample] index=348 true_label=6 predicted_label=6 margin=9.9865
[property] verify that all x' with ||x' - x||_inf <= 0.0100 keep label 6
[export] writing external ONNX model to /var/folders/06/qfjgpg412qn_7l078cqvv2g00000gn/T/marabou_hw3_izqv4tr/external_digits_cnn.onnx
[export] onnx_predicted_label=6
[verify] checking local robustness with epsilon=0.0100 and timeout=10s per target
[verify] target=0 result=unsat runtime=0.02s
[verify] target=1 result=unsat runtime=0.02s
[verify] target=2 result=unsat runtime=0.02s
[verify] target=3 result=unsat runtime=0.01s
[verify] target=4 result=unsat runtime=0.01s
[verify] target=5 result=unsat runtime=0.02s
[verify] target=7 result=unsat runtime=0.01s
[verify] target=8 result=unsat runtime=0.01s
[verify] target=9 result=unsat runtime=0.01s

=== Verification Summary ===
dataset: sklearn digits
model: external 2-layer CNN exported to ONNX
sample_index: 348
true_label: 6
epsilon: 0.0100
final_result: UNSAT for all target labels checked
interpretation: the sample was locally robust within the tested epsilon
```

```
(rai) ➔ hw3 git:(main) ✕ python test.py --epsilon 0.2

[setup] loading sklearn digits dataset
[setup] training small 2-layer CNN
[train] epoch=01 loss=2.3061
[train] epoch=05 loss=1.9715
[train] epoch=10 loss=0.4420
[train] epoch=15 loss=0.7389
[train] epoch=20 loss=0.1630
[eval] test_accuracy=0.9583
[sample] index=348 true_label=6 predicted_label=6 margin=9.9865
[property] verify that all x' with ||x' - x||_inf <= 0.2000 keep label 6
[export] writing external ONNX model to /var/folders/06/qfjgpg412qn_7l078cqvv2g00000gn/T/marabou_hw3_fb02v5/external_digits_cnn.onnx
[export] onnx_predicted_label=6
[verify] checking local robustness with epsilon=0.2000 and timeout=10s per target
[verify] target=0 result=unsat runtime=0.53s
[counterexample] target=0 adv_index=0 l_inf=0.200000
[counterexample] adversarial Bad input:
[[ 0. 0.2 0.2277 0.8 0.4377 0. 0.2 0.2 ]
 [ 0.2 0.2 0.7 0.8947 0.5125 0.2 0.2 0.2 ]
 [ 0.2 0.325 1. 0.2375 0.2 0.2 0.2 0. ]
 [ 0.2 0.3198 1. 0.2375 0.5125 0.2625 0.2 0. ]
 [ 0. 0.6375 0.8408 0. 0.8 1. 0.3075 0.2 ]
 [ 0.1853 0.5125 0.8 0.55 0.85 0.825 0.675 0. ]
 [ 0. 0.2 1. 0.6125 0.5125 0.425 0.7375 0. ]
 [ 0. 0.2 0.3875 0.6125 0.8 0.8 0.575 0.2 ]]
[counterexample] saved visualization to /Users/Sun/Documents/ReliabAI/hw3/counterexample.png

=== Verification Summary ===
dataset: sklearn digits
model: external 2-layer CNN exported to ONNX
sample_index: 348
true_label: 6
epsilon: 0.2000
final_result: SAT (counterexample found)
counterexample_target: 0
counterexample_prediction: 8
```



(위: epsilon=0.01에 대한 실험결과 / 아래: epsilon=0.2에 대한 실험 결과 및 시각화)

본 실험에서 sklearn digits 데이터셋으로 직접 학습한 2-layer CNN을 사용하였으며, 검증은 Marabou의 Python API인 maraboupy로 수행했다.

검증 쿼리는 입력 주변의 L_∞ 반경 epsilon 내에서도 원래 예측 클래스를 유지하는지 확인하는 방식으로, 한 점의 분류 결과를 보는 것이 아닌 입력 주변의 작은 변화까지 고려하여 모델의 안정성을 확인한다는 점에서 의미가 있다고 판단된다.

또, epsilon=0.2에서 SAT을 반환한 것으로 보아 모델이 어느정도 큰 perturbation까지 강건하다는 점을 확인하였고(정확한 epsilon범위에 대한 실험을 진행하지 않았지만 0.1까지 UNSAT을 유지하는 것으로 확인), 모델의 robustness는 절대적이지 않고 입력에 가해지는 perturbation 크기에 따라 달라진다는 점을 알 수 있었다.

실험 과정에서 느낀 Marabou의 장점은 Python API를 이용하여 직접 입력 제약과 출력 제약을 구성할 수 있고, 이를 통해 UNSAT결과를 얻으면 입력 주변의 안정성을 보장할 수 있다는 점이였다.

단점은 설치과정이 처음에는 까다롭고 플랫폼 호환성 문제를 직접 해결해야한다는 점이였다. 또, 큰 사이즈의 모델이나 이미지는 이미지의 차원과, 모델 변수 및 제약이 커지므로 검증시간이 커질것으로 우려된다.